

RAPPORT DE PROJET :

Détection Intelligente des Fake News Politiques

Classification binaire par approche Naive Bayes

sur le dataset ISOT Fake News

Master 1 — Intelligence Artificielle & Objets Connectés

Module : Analyse de données et sécurité

Réalisé par :

El Ghayati Sara

Sirat Rania

Ayman El-Habhab

Fatima Lachal

Fatima Ezzhrae El-Ouali

Ayman Sarhan

Atemga Mbossetaa Wangso David

Encadré par :

Mr.Boujiha Tarik

Année universitaire : 2025-2026

Dédicace

Nous souhaitons dédier ce travail avec une sincère gratitude à toutes les personnes qui, de près ou de loin, ont apporté leur aide, leur soutien ou leur inspiration dans la réalisation de ce projet.

Nos pensées les plus chaleureuses vont à nos familles respectives, dont l'amour inconditionnel, la patience et l'encouragement constant ont été une source essentielle de motivation tout au long de notre parcours.

Nous exprimons également notre profonde reconnaissance à Monsieur **boujiha Tarik** notre encadrant, pour sa disponibilité, ses conseils éclairés, sa bienveillance et son engagement sans faille, qui ont été des repères précieux dans notre cheminement.

Enfin, nous adressons une pensée à nous-mêmes, en tant que membres actifs et engagés dans cette aventure, pour notre détermination, notre esprit d'équipe et notre persévérance face aux défis rencontrés.

Ce projet représente bien plus qu'un simple travail académique, il incarne une expérience humaine et intellectuelle marquante que nous garderons longtemps en mémoire.

Remerciements

Nous tenons à exprimer notre profonde gratitude envers toutes les personnes qui ont contribué, de près ou de loin, à la réalisation de ce projet académique.

Nos remerciements les plus sincères s'adressent en premier lieu à notre encadrant pédagogique, pour ses conseils éclairés, sa disponibilité permanente et la rigueur scientifique qu'il nous a inculquée tout au long de ce module.

Nous remercions également l'Université Ibn Tofail de Kénitra et le département Master 1 Intelligence Artificielle & Objets Connectés pour la qualité de la formation dispensée et les ressources mises à notre disposition.

Notre gratitude va aussi à l'équipe de recherche de l'Université de Victoria pour la mise à disposition du dataset ISOT Fake News, qui constitue le socle empirique de ce travail.

Enfin, nous remercions nos collègues de promotion pour les échanges scientifiques enrichissants et l'esprit de collaboration qui a animé toute cette année universitaire.

Résumé

Dans le cadre de ce projet, nous avons développé un système intelligent de détection des fake news reposant sur les techniques de traitement automatique du langage naturel (NLP) et la classification supervisée. L'objectif principal est de concevoir une application capable d'analyser automatiquement des articles ou des textes d'actualité afin de déterminer s'ils correspondent à une information réelle ou à une fausse information.

Pour la réalisation de ce travail, le dataset **ISOT Fake News** a été utilisé. Il est composé d'articles authentiques et de fausses informations provenant de différentes sources. Une phase de prétraitement des données a été mise en œuvre afin de nettoyer les textes, supprimer les éléments non pertinents et préparer les données pour l'apprentissage automatique. Les textes ont ensuite été transformés en représentations numériques exploitables à l'aide de la méthode **TF-IDF**, largement utilisée dans les tâches de classification de textes.

L'étude s'est principalement concentrée sur les approches de **classification bayésienne**, à travers l'implémentation des algorithmes **Multinomial Naive Bayes** et **Complement Naive Bayes**, choisis pour leur efficacité et leur pertinence dans les problématiques de classification de données textuelles. Afin d'enrichir l'analyse comparative et d'évaluer la robustesse des modèles bayésiens, plusieurs **modèles linéaires de référence** ont également été intégrés, notamment la **régression logistique**, le **Linear Support Vector Machine (LinearSVC)**, le **SGDClassifier** basé sur un apprentissage stochastique, ainsi que le **Passive-Aggressive Classifier**, adapté aux scénarios d'apprentissage en ligne.

Les performances des différents modèles ont été évaluées à l'aide de métriques classiques telles que l'accuracy, la précision, le rappel (recall) et le F1-score, permettant d'analyser et de comparer objectivement les résultats obtenus. Cette

évaluation a permis d'identifier les modèles les plus performants pour la détection automatique des fake news.

En parallèle de la partie analytique, une application web interactive a été développée en utilisant **FastAPI** pour le backend et **HTML, CSS et JavaScript** pour le frontend. Cette application offre à l'utilisateur la possibilité de saisir un texte d'actualité et d'obtenir, en temps réel, une prédiction indiquant si l'information est réelle ou fausse, à travers un dashboard interactif.

Les résultats obtenus confirment l'efficacité des approches bayésiennes dans la détection des fake news, tout en soulignant l'intérêt d'une comparaison avec des modèles linéaires de référence. Ce projet met ainsi en évidence le rôle essentiel des techniques d'intelligence artificielle et de Machine Learning dans la lutte contre la désinformation numérique.

Abstract

This project presents an intelligent fake news detection system based on Natural Language Processing (NLP) and supervised machine learning techniques. The main objective is to automatically classify news articles as either real or fake through textual analysis.

The study is conducted using the **ISOT Fake News** dataset, which contains both real and fake news articles. A data preprocessing phase was performed to clean and prepare the textual data for modeling. The **TF-IDF** technique was then applied to transform the text into numerical feature vectors suitable for machine learning algorithms.

The proposed approach mainly focuses on **Bayesian classification methods**, implemented through **Multinomial Naive Bayes** and **Complement Naive Bayes**, due to their effectiveness in text classification tasks. To enrich the comparative analysis and evaluate the robustness of Bayesian models, several **linear supervised models** were also used as reference approaches, including **Logistic Regression**, **Linear Support Vector Machine**, **SGDClassifier**, and **Passive-Aggressive Classifier**.

Model performance was evaluated using standard metrics such as **accuracy**, **precision**, **recall**, and **F1-score** in order to identify the most effective classification model.

In addition, a web-based interactive application was developed using **FastAPI** for the backend and **HTML**, **CSS**, and **JavaScript** for the frontend. This application allows users to input news text and receive real-time predictions through an interactive dashboard indicating whether the news is real or fake.

Table des matières

Introduction Générale	12
Chapitre 1 : État de l'art et Présentation du Projet	14
Introduction du chapitre 1	15
1.1. Les fake news : concepts et définitions	16
1.1.1. Définition des fake news	16
1.1.2. Typologies des fake news :	16
1.1.3. Impacts des fake news	18
1.2. Détection des fake news : état de l'art	19
1.2.1. Approches traditionnelles de détection	19
1.2.2. Approches automatiques	21
1.2.3. Classification de textes dans la détection des fake news	22
1.3. Les approches de Machine Learning pour la détection des fake news	23
1.3.2. Les méthodes de classification bayésienne	24
1.3.3. Modèles supervisés de comparaison	25
Conclusion du Chapitre 1	26
Chapitre 2 : Développement et expérimentation du modèle de classification	27
Introduction du Chapitre 2	28
2.1. Présentation et analyse du dataset	28
2.2. Prétraitement NLP des données textuelles	30
2.3. Analyse exploratoire des données (EDA)	31
2.3.2. Analyse des mots dominants avec WordCloud	33
2.3.3. Analyse des mots les plus fréquents	34
2.3.4. Analyse comparative par sujet	35
2.3.5. Heatmap de corrélation des features textuelles	37
2.4. Vectorisation TF-IDF	39
2.5. Modélisation des données textuelles	41
2.5.1. Modélisation avec Multinomial Naive Bayes	41
2.5.2. Modélisation avec Complement Naive Bayes	43
2.5.3. Régression Logistique	44
2.6.1. Validation croisée	47
2.6.2. Analyse des features discriminantes	48
Conclusion du Chapitre 2	51
Chapitre 3 : Conception et développement de l'application web de détection des fake news	52
Introduction du Chapitre 3	53
3.1. Architecture générale de l'application	53
3.2. Backend API FastAPI	53
3.3. Frontend Interface React	54
3.4. Intégration des modèles ML dans l'application	55
4. Interface utilisateur	56
4.1. Page principale : Analyse de texte et résultats dynamiques	56

4.1.1 Résultat de détection Fake News	57
4.1.2 Résultat de détection Real News	58
4.1.3 Chatbot intelligent	58
4.2. Dashboard statistique	59
4.3 Page Historique	60
4.4 Page À propos	61
3.5. Tests de l'application	62
3.5.1. Tests unitaires du classificateur	62
3.5.2. Tests de l'API	62
3.5.3. Génération des modèles de démonstration	63
Conclusion du Chapitre 3	63
Conclusion Générale	65
Annexes	66
1. Préprocessement NLP	66
2. Les histogrammes de longueur des textes par classe et Les boxplots du nombre de mots .	66
3. Les WordClouds Fake vs Real	67
4. distribution subject par classe	67
5. La heatmap de corrélation des features textuelles.	67
6. Paramétrage TF-IDF et GridSearch	68
7. Modèles supplémentaires	68
8. Visualisations de performance	69
9. Validation croisée	69
Webgraphie	70

Table des figures

Figure 1 :Fake News	16
Figure 2 : Fake news sociales et médiatiques	18
Figure 3 :Impact des fake news	19
Figure 4 :Schéma conceptuel avec les étapes Checkability, Verifiability et Viralization	20
Figure 5 :Pipeline NLP avancé	22
Figure 6 :Processus de détection de fausses informations à partir d'articles	23
Figure 7 :Chaîne de traitement documentaire	24
Figure 8 :Carte des variantes principales du classificateur Naive Bayes	25
Figure 9 :Pipeline ML avec réduction dimensionnelle	26
Figure 10 :résumé structurel du dataset ISOT avec répartition des classes Fake/Real.	29
Figure 11 :Table de nettoyage	31
Figure 12 :histogramme et boxplot comparant la taille des textes Fake vs Real.	32
Figure 13 :Nuages de mots Fake vs Real	33
Figure 14 :Top 20 mots Fake vs Real	34
Figure 15 :Distribution des sujets (REAL VS FAKE)	35
Figure 16 :Longueur moyenne par sujet	36
Figure 17 :Heatmap de corrélation	38
Figure 18 :Recherche alpha MultinomialNB	42
Figure 19 :Matrice de confusion MultinomialNB	43
Figure 20 :Performance ComplementNB	44
Figure 21 :Performance Logistic Regression	45
Figure 22 :Tableau comparatif modèles	46
Figure 23 :Heatmap des performances	46
Figure 24 :Courbes ROC et PR	47
Figure 25 :Confusions Multinomial vs ComplementNB	47
Figure 26 :Table comparatif F1 et Accuracy	48
Figure 27 :Features discriminants ISOT	49
Figure 28 :FastAPI + Python	54
Figure 29 :Gemini API	54
Figure 30 :Vite + React	55
Figure 31 :pipeline d'integration models ML	56
Figure 32 :page d'accueil de FakeShield pour analyser un texte et détecter la désinformation.	57
Figure 33 :interface affichant un verdict "FAKE" avec indicateurs détectés.	57
Figure 34 :interface affichant un verdict "REAL" avec score de confiance.	58
Figure 35 :Assistant FakeShield	59
Figure 36 :Dashboard FakeShield Réel	59
Figure 37 :Dashboard FakeShield Fake	60
Figure 38 :Historique FakeShield	61
Figure 39 :À propos FakeShield	62

Liste des tableaux

Table 1 :pipeline de Prétraitement NLP des données textuelles	30
Table 2 :feature et leur description	37
Table 3 :Comparaison des configurations TF-IDF	40

Liste des abréviations

- ML → Machine Learning
- NLP → Natural Language Processing
- API → Application Programming Interface
- TF-IDF → Term Frequency – Inverse Document Frequency

Introduction Générale

Avec la digitalisation croissante de l'information et l'essor des plateformes numériques, les réseaux sociaux et les sites d'actualité sont devenus des canaux majeurs de diffusion de l'information. Toutefois, cette facilité d'accès s'accompagne d'un phénomène préoccupant : la propagation rapide des fake news, c'est-à-dire des informations fausses ou trompeuses présentées comme véridiques. Ce phénomène constitue aujourd'hui un enjeu important en raison de son impact sur l'opinion publique, les décisions politiques et la crédibilité de l'information.

Face à l'augmentation continue du volume de données textuelles diffusées quotidiennement, les méthodes traditionnelles de vérification de l'information montrent leurs limites. Dans ce contexte, la détection automatique des fake news s'impose comme une problématique essentielle dans le domaine de l'intelligence artificielle, notamment à travers le traitement automatique du langage naturel (Natural Language Processing – NLP), qui permet l'analyse et la compréhension des contenus textuels.

Ce projet s'inscrit dans cette problématique et vise à concevoir un système de classification automatique des articles de presse à l'aide de techniques de Machine Learning. Il repose sur l'exploitation du dataset **ISOT Fake News**, composé d'articles authentiques et de fausses informations, afin d'entraîner et d'évaluer des modèles capables de distinguer efficacement les deux catégories.

L'approche adoptée se concentre principalement sur les méthodes de classification bayésienne, reconnues pour leur efficacité dans la classification de textes. Une comparaison avec des modèles de classification supervisée de référence, tels que la régression logistique et d'autres modèles linéaires, est également réalisée afin d'évaluer la robustesse des résultats obtenus.

La méthodologie mise en œuvre comprend le prétraitement des données textuelles, leur transformation en représentations numériques à l'aide de la méthode TF-IDF, l'entraînement des modèles de classification et l'évaluation de leurs performances à l'aide de métriques appropriées.

Le rapport est structuré en trois chapitres : le premier est consacré à l'état de l'art relatif aux fake news et à leur détection automatique, le deuxième présente la méthodologie adoptée et les expérimentations réalisées, et le troisième décrit la conception et l'implémentation d'une application web interactive permettant la détection des fake news en temps réel.

Chapitre 1 : État de l’art et **Présentation du Projet**

Introduction du chapitre 1

La problématique des fake news s'impose aujourd'hui comme un enjeu majeur dans un contexte marqué par la diffusion massive et rapide de l'information à travers les plateformes numériques. La multiplication de contenus non vérifiés ou trompeurs soulève des questions essentielles relatives à la fiabilité de l'information, à l'influence sur l'opinion publique et à la crédibilité des sources médiatiques. Face à ces défis, la recherche scientifique s'intéresse de plus en plus aux approches automatiques permettant d'identifier et de classifier les informations fausses.

L'objectif de ce premier chapitre est de poser le cadre conceptuel et théorique du projet. Il vise à présenter les notions fondamentales liées aux fake news, à analyser leurs caractéristiques et à exposer les principales approches proposées dans la littérature pour leur détection. Une attention particulière est accordée aux méthodes basées sur le Machine Learning et le traitement automatique du langage naturel, qui constituent aujourd'hui les axes dominants de recherche dans ce domaine.

Ce chapitre a également pour but de situer le projet par rapport à l'existant et de présenter son positionnement général. Il introduit le contexte de l'étude, les objectifs poursuivis ainsi que le jeu de données utilisé, à savoir le dataset ISOT Fake News, largement exploité dans les travaux académiques. Le choix d'orienter ce travail vers les approches de classification bayésienne est également justifié, en cohérence avec la thématique principale du projet.

Ainsi, ce premier chapitre fournit les bases théoriques et le cadre général nécessaires à la compréhension du travail réalisé, tout en préparant le terrain pour les chapitres suivants.

1.1. Les fake news : concepts et définitions

1.1.1. Définition des fake news

Le terme *fake news* désigne des informations fausses, inexactes ou volontairement trompeuses, présentées sous la forme d'articles journalistiques ou de contenus d'actualité crédibles. Ces informations sont généralement conçues dans le but de manipuler l'opinion publique, d'influencer des décisions politiques ou économiques, ou encore de générer des revenus à travers la viralité sur les plateformes numériques.

Il est important de distinguer les fake news de deux notions souvent associées : la désinformation et la mésinformation. La **désinformation** correspond à la diffusion intentionnelle d'informations fausses dans un objectif de manipulation ou de propagande. En revanche, la **mésinformation** désigne la diffusion d'informations incorrectes sans intention malveillante, souvent due à une mauvaise interprétation ou à une vérification insuffisante des sources.

Ces distinctions sont essentielles dans le cadre de la détection automatique des fake news, car elles mettent en évidence la complexité du phénomène et la difficulté à identifier de manière fiable les contenus trompeurs à partir de leurs seules caractéristiques textuelles.



Figure 1:Fake News

1.1.2. Typologies des fake news :

Les fake news peuvent être classées selon leur domaine d'application et leur objectif principal. Parmi les principales typologies, on distingue :

➤ **Fake news politiques**

Les fake news politiques constituent l'une des formes les plus répandues et les plus sensibles. Elles visent généralement à influencer l'opinion publique, à manipuler les électeurs ou à discréditer des personnalités politiques. Ces contenus apparaissent fréquemment lors de périodes électorales ou de crises politiques.

➤ **Fake news économiques**

Les fake news économiques concernent des informations trompeuses liées aux marchés financiers, aux entreprises ou aux politiques économiques. Elles peuvent provoquer des réactions excessives, telles que des fluctuations boursières ou des pertes financières importantes, en diffusant de fausses rumeurs ou des données erronées.

➤ **Fake news sociales et médiatiques**

Cette catégorie regroupe les fake news portant sur des sujets sociaux, culturels ou médiatiques. Elles exploitent souvent des thèmes émotionnels ou sensationnalistes afin de maximiser leur propagation sur les réseaux sociaux et d'attirer l'attention d'un large public.



Figure 2: Fake news sociales et médiatiques

1.1.3. Impacts des fake news

La diffusion massive des fake news engendre des impacts significatifs à plusieurs niveaux.

➤ **Influence sur l'opinion publique**

Les fake news peuvent orienter la perception des individus en diffusant des informations biaisées ou erronées. Elles exploitent souvent les émotions et les croyances préexistantes, renforçant ainsi la polarisation des opinions.

➤ **Conséquences sociales et politiques**

À l'échelle sociétale, les fake news contribuent à la désinformation collective, à la méfiance envers les institutions et à l'instabilité sociale. Dans le domaine politique, elles peuvent perturber les processus démocratiques et influencer les résultats électoraux.

➤ **Problèmes de crédibilité de l'information**

La prolifération des fake news affaiblit la crédibilité des médias traditionnels et complique la distinction entre informations fiables et contenus trompeurs. Cette situation renforce le besoin de solutions automatiques capables d'assister les utilisateurs dans l'évaluation de la fiabilité des informations.




Figure 3: Impact des fake news

1.2. Détection des fake news : état de l'art

La détection des fake news constitue un champ de recherche en constante évolution, motivé par la nécessité de lutter contre la désinformation à grande échelle. Les approches proposées dans la littérature peuvent être regroupées en deux grandes catégories : les approches traditionnelles, reposant principalement sur l'intervention humaine, et les approches automatiques, basées sur les techniques de l'intelligence artificielle.

1.2.1. Approches traditionnelles de détection

- Vérification manuelle

La vérification manuelle consiste à analyser les contenus d'information de manière humaine afin d'évaluer leur véracité. Cette méthode repose sur l'expertise de

journalistes, de chercheurs ou de spécialistes de la vérification de l'information. Elle implique l'analyse des sources, la comparaison avec des informations fiables et l'évaluation de la cohérence du contenu.

Bien que cette approche permette d'obtenir des résultats précis, elle demeure coûteuse en temps et en ressources humaines. De plus, elle ne peut pas être appliquée efficacement à grande échelle face au volume massif de contenus générés quotidiennement sur les plateformes numériques.

- Fact-checking et limites humaines

Le fact-checking est une pratique journalistique visant à vérifier les faits avancés dans un article ou une déclaration publique. Des organismes spécialisés se consacrent à cette activité afin de lutter contre la désinformation. Toutefois, malgré son importance, le fact-checking présente plusieurs limites, notamment la subjectivité humaine, les délais de vérification et l'impossibilité de traiter l'ensemble des informations diffusées en temps réel.

Ces contraintes ont conduit à la recherche de solutions automatisées capables de compléter et d'assister les méthodes traditionnelles.




Figure 4: Schéma conceptuel avec les étapes Checkability, Verifiability et Viralization

1.2.2. Approches automatiques

➤ **Rôle de l'intelligence artificielle**

Les approches automatiques de détection des fake news s'appuient principalement sur l'intelligence artificielle afin d'analyser rapidement de grandes quantités de données textuelles. Ces méthodes permettent d'identifier des schémas, des régularités et des caractéristiques propres aux informations fausses à partir de données existantes.

L'intelligence artificielle offre ainsi la possibilité de développer des systèmes capables d'évaluer automatiquement la crédibilité des contenus, réduisant considérablement le temps nécessaire à leur analyse par rapport aux méthodes manuelles.

➤ **Importance du traitement automatique du langage naturel (NLP)**

Le traitement automatique du langage naturel joue un rôle central dans la détection automatique des fake news. Il permet de transformer des textes non structurés en informations exploitables par les algorithmes de Machine Learning. Grâce aux techniques de NLP, il devient possible d'analyser le vocabulaire, la structure des phrases et les relations entre les mots afin de mieux comprendre le contenu des articles.

Le NLP constitue donc un pilier fondamental des systèmes de détection automatique, en facilitant l'extraction de caractéristiques pertinentes à partir des données textuelles.




Figure 5: Pipeline NLP avancé

1.2.3. Classification de textes dans la détection des fake news

➤ Principe général de la classification de textes

La classification de textes est une tâche fondamentale du traitement automatique du langage naturel qui consiste à attribuer une ou plusieurs catégories à un document textuel. Dans le contexte de la détection des fake news, cette tâche vise à déterminer si un article appartient à la catégorie des informations réelles ou à celle des informations fausses.

Cette approche repose sur l'analyse des caractéristiques linguistiques et statistiques des textes, permettant de distinguer automatiquement les différentes classes à partir de données étiquetées.

➤ Place du Machine Learning dans la détection automatique

Le Machine Learning occupe une place centrale dans la classification automatique des fake news. Les modèles d'apprentissage supervisé sont entraînés à partir de données préalablement étiquetées afin d'apprendre à reconnaître les différences entre les articles réels et les articles faux. Ces modèles sont ensuite capables de généraliser leurs apprentissages à de nouveaux textes.

L'intégration du Machine Learning dans la détection des fake news permet ainsi de concevoir des systèmes adaptatifs et évolutifs, capables de s'améliorer avec l'augmentation des données disponibles.




Figure 6:Processus de détection de fausses informations à partir d'articles

1.3. Les approches de Machine Learning pour la détection des fake news

Le Machine Learning occupe une place centrale dans la détection automatique des fake news, en raison de sa capacité à apprendre à partir de données textuelles et à généraliser ces apprentissages à de nouveaux contenus. Dans la littérature, plusieurs approches ont été proposées afin de classifier automatiquement les articles d'actualité en informations réelles ou fausses. Ces approches reposent principalement sur l'apprentissage supervisé et, plus particulièrement, sur des modèles adaptés à la classification de textes.

1.3.1. Apprentissage supervisé

L'apprentissage supervisé est une approche du Machine Learning qui consiste à entraîner un modèle à partir de données étiquetées, c'est-à-dire des données pour

lesquelles la classe cible est connue à l'avance. Dans le cas de la détection des fake news, chaque article est associé à une étiquette indiquant s'il s'agit d'une information réelle ou fausse.

Cette approche permet aux modèles d'apprendre les caractéristiques distinctives des textes appartenant à chaque catégorie. Une fois entraînés, les modèles sont capables de prédire la classe de nouveaux articles en se basant sur les connaissances acquises lors de la phase d'apprentissage. L'apprentissage supervisé est largement utilisé dans la détection des fake news en raison de sa simplicité conceptuelle et de son efficacité lorsqu'un volume suffisant de données annotées est disponible.




Figure 7: Chaîne de traitement documentaire

1.3.2. Les méthodes de classification bayésienne

Les méthodes de classification bayésienne reposent sur le théorème de Bayes, qui permet de calculer la probabilité qu'un document appartienne à une classe donnée en fonction des caractéristiques observées. Ces approches sont particulièrement adaptées à la classification de textes, car elles offrent un bon compromis entre simplicité, rapidité de calcul et performance.

Dans le domaine de la détection des fake news, les classifieurs bayésiens sont largement utilisés en raison de leur capacité à traiter efficacement des données textuelles de grande dimension. Ils supposent généralement une indépendance conditionnelle entre les mots d'un document, ce qui simplifie les calculs tout en donnant de bons résultats pratiques. Les modèles bayésiens constituent ainsi une référence importante dans l'état de l'art de la classification automatique des textes.




Figure 8: Carte des variantes principales du classificateur Naive Bayes

1.3.3. Modèles supervisés de comparaison

En complément des approches bayésiennes, la littérature propose également l'utilisation d'autres modèles de classification supervisée afin de comparer les performances obtenues. Parmi ces modèles, la régression logistique est fréquemment utilisée comme méthode de référence dans les tâches de classification de textes.

La régression logistique permet de modéliser la probabilité d'appartenance d'un document à une classe donnée à partir de ses caractéristiques. Bien qu'elle repose sur un modèle statistique simple, elle offre souvent de bonnes performances et constitue

un point de comparaison pertinent pour évaluer l'efficacité des méthodes bayésiennes dans la détection des fake news.




Figure 9: Pipeline ML avec réduction dimensionnelle

Conclusion du Chapitre 1

Ce premier chapitre a permis de poser le cadre général de la problématique des fake news en présentant leurs définitions, leurs typologies ainsi que leurs impacts sur la société. Il a également offert une vue d'ensemble des principales approches existantes pour leur détection, en mettant en évidence l'évolution des méthodes traditionnelles vers des solutions automatiques basées sur l'intelligence artificielle et le Machine Learning.

Cette revue de l'état de l'art met en évidence la pertinence de la classification automatique des textes comme solution efficace face à l'ampleur et à la rapidité de propagation des fausses informations. Elle justifie ainsi le choix d'une approche supervisée pour la détection des fake news.

Dans le chapitre suivant, nous détaillerons la solution proposée en présentant l'ensemble du pipeline de traitement des données, la méthodologie adoptée, les modèles de classification utilisés ainsi que les résultats expérimentaux obtenus.

Chapitre 2 : Développement et expérimentation du modèle de classification

Introduction du Chapitre 2

Après avoir défini les concepts fondamentaux et les principales approches liées à la détection des fake news dans le chapitre précédent, ce chapitre est consacré à la présentation de la solution proposée et de la méthodologie adoptée.

Il décrit les différentes étapes du pipeline de traitement des données, depuis la présentation du dataset utilisé jusqu'à la mise en œuvre des modèles de classification. Nous détaillons également les phases de préparation des données, de transformation des textes en représentations numériques à l'aide de la méthode TF-IDF, ainsi que les algorithmes de machine learning appliqués.

Enfin, ce chapitre présente l'évaluation des performances des modèles à travers plusieurs métriques afin d'analyser l'efficacité de la solution proposée.

2.1. Présentation et analyse du dataset

Dans le cadre de ce projet, nous avons utilisé le dataset **ISOT Fake News**, un jeu de données largement utilisé dans les travaux de recherche portant sur la détection automatique des fake news et la classification de textes. Ce dataset a été développé par le laboratoire *Information Security and Object Technology (ISOT)* de l'Université de Victoria.

Le dataset est composé de deux fichiers principaux :

- **True.csv** : contient des articles d'actualité réels provenant principalement de l'agence de presse Reuters ;
- **Fake.csv** : contient des articles considérés comme fake news provenant de différentes sources non vérifiées.

Contrairement à certains datasets présentant des problèmes de labels ou d'annotations, le dataset ISOT offre une structure claire et directement exploitable pour les tâches de

classification supervisée. Les classes sont définies de manière fiable à partir de la source des articles, ce qui facilite l'entraînement des modèles de Machine Learning.

Les données sont organisées sous forme tabulaire et contiennent plusieurs colonnes textuelles décrivant les articles de presse. Les principales colonnes utilisées dans ce projet sont :

- **title** : le titre de l'article ;
- **text** : le contenu complet de l'article ;
- **subject** : la catégorie ou le sujet de l'article ;
- **date** : la date de publication.

Après le chargement des fichiers, les deux datasets ont été fusionnés afin de construire un dataset unique contenant les articles réels et les fake news, avec l'ajout d'un label de classification permettant d'identifier chaque catégorie.

Diagnostic ISOT – structure des fichiers

```
-----
Fake.csv      shape=(23481, 4)
Colonnes     : ['title', 'text', 'subject', 'date']
Sujets       : {'News': 9858, 'politics': 6841, 'left-news': 4459, 'Government News': 1578, 'US_News': 783, 'Middle-east': 778}
Valeurs NaN  : aucune

True.csv      shape=(21417, 4)
Colonnes     : ['title', 'text', 'subject', 'date']
Sujets       : {'politicsNews': 11272, 'worldnews': 18145}
Valeurs NaN  : aucune
```

Taux de remplissage des colonnes meta :

```
subject  44898/44898  (100.0% remplie)
date     44898/44898  (100.0% remplie)
```

Distribution subject par classe :

```
label subject
Fake Government News  1578
Middle-east          778
News                 9858
US_News              783
left-news            4459
politics              6841
Real politicsNews    11272
worldnews            18145
```

Conclusion : subject est un signal trop fort et spécifique à ISOT – l'inclure dans le pipeline TF-IDF reviendrait à apprendre la source, pas le contenu. On l'écarte du pipeline de modélisation. Il est conservé uniquement pour l'EDA comparative (section #).

Shape apres fusion et deduplication : (39105, 3)




Figure 10: résumé structurel du dataset ISOT avec répartition des classes Fake/Real.

Interpretation :

ISOT presente une distribution quasi-equilibree : Fake $\approx$ 52 %, Real $\approx$ 48 %. Ce quasi-equilibre est un avantage majeur par rapport a FakeNewsNet (78/22) : l'accuracy redevient une metrique lisible, et les modeles n'ont pas besoin de compensations specifiques pour la classe minoritaire. On conserve neanmoins [f1_macro] comme metrique principale par rigueur methodologique

2.2. Prétraitement NLP des données textuelles

Le prétraitement des données textuelles constitue une étape essentielle dans les tâches de traitement automatique du langage naturel. Cette phase permet de nettoyer et de normaliser les textes afin d'améliorer la qualité des données utilisées lors de l'apprentissage des modèles de classification.

Dans ce projet, une fonction **clean_text** a été développée afin d'appliquer plusieurs opérations de nettoyage et de transformation sur les articles du dataset. Les différentes étapes du prétraitement sont présentées dans le tableau suivant :

Table 1: pipeline de Prétraitement NLP des données textuelles

Étape	Opération appliquée
1	Conversion du texte en minuscules
2	Suppression des URLs et liens web
3	Suppression des balises HTML
4	Suppression des caractères non alphabétiques
5	Tokenisation des textes avec word_tokenize
6	Suppression des stopwords de la langue anglaise
7	Lemmatisation des mots avec WordNetLemmatizer
8	Filtrage des mots de longueur inférieure à 3 caractères

La suppression des stopwords permet d'éliminer les mots très fréquents n'apportant pas d'information significative à la classification, tandis que la lemmatisation permet de réduire les mots à leur forme de base afin d'améliorer la généralisation des modèles.

Après l'application du prétraitement NLP sur l'ensemble des articles, une nouvelle colonne nommée **clean** a été créée afin de stocker les textes nettoyés et normalisés. Les articles contenant un texte trop court après nettoyage ont également été supprimés afin de conserver uniquement les données pertinentes pour l'apprentissage.

Le prétraitement a été appliqué sur environ 44 000 articles, ce qui a conduit à un dataset final de dimension :

	statement	clean	label
0	Many 'lost' voters say they have found their c...	many lost voter say found candidate trump wash...	1
1	Iranian Revolutionary Guards commander, anothe...	iranian revolutionary guard commander another ...	1
2	Cambodian leader gets China's backing as West ...	cambodian leader get china backing west condem...	1

Figure 11:Table de nettoyage

2.3. Analyse exploratoire des données (EDA)

L'analyse exploratoire des données (*Exploratory Data Analysis — EDA*) constitue une étape importante avant la phase de modélisation. Elle permet de mieux comprendre la structure des données, d'identifier les caractéristiques principales des textes et d'analyser les différences existantes entre les fake news et les real news.

Dans cette étude, plusieurs analyses statistiques et visuelles ont été réalisées afin d'extraire des informations pertinentes à partir des données textuelles prétraitées.

2.3.1. Analyse de la longueur des textes et du nombre de mots

Afin d'étudier les caractéristiques générales des articles, deux indicateurs ont été calculés :

- la longueur des textes (text_length) ;
- le nombre de mots (word_count).

Les distributions obtenues permettent de comparer les fake news et les real news selon leur taille moyenne et leur richesse textuelle.

Les résultats montrent que les articles réels possèdent généralement des textes plus longs et plus détaillés que les fake news. Cette différence constitue un premier signal exploitable pour la classification automatique.

Les statistiques descriptives obtenues confirment également cette tendance et montrent une différence notable entre les deux catégories d'articles.




Figure 12: histogramme et boxplot comparant la taille des textes Fake vs Real.

Interpretation :

Sur ISOT, les real news (Reuters) sont notablement plus longues

que les fake news. Les articles Reuters suivent des standards journalistiques rigoureux

qui impliquent des développements plus étoffés, tandis que les fake news sont souvent

plus courtes et plus directes dans leurs assertions. Cette différence de longueur

est un signal discriminant plus marqué que sur FakeNewsNet

2.3.2. Analyse des mots dominants avec WordCloud

Afin d'identifier les termes les plus fréquents dans chaque catégorie d'articles, des représentations visuelles de type *WordCloud* ont été générées pour les fake news et les real news.

Les résultats montrent une séparation lexicale claire entre les deux classes :

- les fake news contiennent principalement des termes politiques américains et plusieurs noms propres fréquemment associés à l'actualité politique ;
- les real news présentent un vocabulaire plus diversifié lié à la couverture journalistique internationale.

Cette différence lexicale met en évidence l'existence de signaux textuels importants pouvant être exploités par les modèles de classification.



Figure 13: Nuages de mots Fake vs Real

Interpretation :

Les wordclouds revelent une separation lexicale nette entre les deux classes.

Les fake news sont dominees par des termes politiques americains specifiques et des noms propres

associes a des controverses, tandis que les real news affichent un vocabulaire

plus international et diplomatique, typique du style Reuters.

2.3.3. Analyse des mots les plus fréquents

Une analyse des mots les plus fréquents a également été réalisée afin d'étudier les termes dominants dans chaque classe.

Les barplots obtenus confirment les observations réalisées avec les WordClouds. Les fake news sont fortement concentrées autour de certains thèmes politiques américains, tandis que les real news présentent un vocabulaire plus varié et plus généraliste.




Figure 14: Top 20 mots Fake vs Real

Interpretation :

Les barplots confirment la separation lexicale observee dans les wordclouds.

Les mots les plus frequents dans les fake news sont principalement des noms propres et des termes politiques americains, refletant la concentration thematique de cette source.

Les real news montrent un vocabulaire plus diversifie avec des termes generiques

de la couverture journalistique internationale

2.3.4. Analyse comparative par sujet

Le dataset ISOT contient une colonne subject indiquant la thématique de chaque article. Cette information a été utilisée afin d'analyser la distribution des sujets selon les différentes classes.

Les résultats montrent une asymétrie importante entre les fake news et les real news :

- les fake news sont majoritairement concentrées sur la politique américaine ;
- les real news couvrent plusieurs thématiques telles que la politique internationale, l'économie, la technologie ou encore le sport.

Cette observation met en évidence un biais potentiel du dataset. En effet, le modèle pourrait apprendre à reconnaître le domaine des articles plutôt que leur style rédactionnel. Pour cette raison, la variable subject n'a pas été intégrée dans le pipeline de modélisation afin d'éviter un biais de généralisation.

Par ailleurs, l'analyse comparative montre que les articles réels restent généralement plus longs que les fake news, indépendamment du sujet traité.




Figure 15: Distribution des sujets (REAL VS FAKE)

Interpretation :

La distribution par sujet revele une asymetrie importante :

les fake news sont presque exclusivement concentrees sur la politique americaine, tandis que les real news couvrent un spectre thematique beaucoup plus large(politique mondiale, economie, sport, technologie).

Cette asymetrie a une consequence directe sur le modele : il risque d'apprendre le domaine autant que le style d'ecriture. C'est pourquoi `subject` est exclu

du pipeline de modelisation — l'inclure introduirait un biais de source

qui ne serait pas generalisable a d'autres datasets.




Figure 16:Longueur moyenne par sujet

Interpretation :

Pour chaque sujet partage entre les deux classes,

les real news sont systematiquement plus longues que les fake news.

Cette observation renforce la correlation positive entre longueur et label Real

observee dans l'EDA generale, et confirme que ce signal est robuste

indépendamment du sujet traité.

2.3.5. Heatmap de corrélation des features textuelles

Dans cette étape, plusieurs caractéristiques numériques ont été extraites directement à partir des textes afin d'étudier leur relation avec le label de classification.

Les principales features calculées sont présentées dans le tableau suivant :

Table 2:feature et leur description

Feature	Description
text_length	Nombre de caractères du texte nettoyé
word_count	Nombre de mots du texte nettoyé
unique_word_ratio	Diversité lexicale : mots uniques / mots totaux
caps_ratio	Proportion de majuscules dans le texte brut
excl_ratio	Proportion de points d'exclamation
digit_ratio	Proportion de chiffres
avg_word_len	Longueur moyenne des mots

L'analyse de corrélation montre que certaines variables présentent une relation plus importante avec le label, notamment :

- avg_word_len
- caps_ratio
- excl_ratio

Ces résultats indiquent que les caractéristiques stylistiques des textes constituent des signaux utiles pour la détection automatique des fake news.

Statistiques descriptives des features numeriques :								
	text_length	word_count	unique_word_ratio	caps_ratio	excl_ratio	digit_ratio	avg_word_len	label
count	39100.0000	39100.0000	39100.0000	39100.0000	39100.0000	39100.0000	39100.0000	39100.0000
mean	1717.5586	234.5676	0.7015	0.0543	0.0004	0.0061	6.3038	0.5421
std	1333.5930	179.0648	0.0795	0.0544	0.0016	0.0074	0.3593	0.4982
min	22.0000	3.0000	0.1635	0.0104	0.0000	0.0000	4.0909	0.0000
25%	926.0000	128.0000	0.6514	0.0340	0.0000	0.0012	6.0811	0.0000
50%	1551.0000	214.0000	0.6971	0.0418	0.0000	0.0041	6.3109	1.0000
75%	2151.0000	294.0000	0.7443	0.0550	0.0000	0.0082	6.5325	1.0000
max	37915.0000	4910.0000	1.0000	0.8529	0.0392	0.2743	9.0134	1.0000




Figure 17:Heatmap de corrélation

Interpretation :

Sur ISOT, les correlations sont plus prononcées qu'attendu. `text\_length` et `word\_count` affichent une correlation positive forte avec Real (articles Reuters plus longs), tandis que `caps\_ratio` et `excl\_ratio` montrent une correlation negative (fake news plus expressives typographiquement).

Le `digit\_ratio` corréle positivement avec Real : les articles journalistiques citent plus de chiffres (statistiques, dates, prix) que les fake news. Ces signaux sont exploitables

leur integration comme features supplementaires aux cotes de TF-IDF constituerait une amelioration directe du pipeline.

2.4. Vectorisation TF-IDF

Après l'analyse exploratoire des données, les textes ont été transformés en représentations numériques à l'aide de la méthode TF-IDF (*Term Frequency – Inverse Document Frequency*). Cette étape est nécessaire afin de permettre aux modèles de Machine Learning de traiter les données textuelles.

Pour adapter la vectorisation à la taille du dataset ISOT, plusieurs paramètres ont été configurés :

- `max_features = 10000`
- `ngram_range = (1,2)`
- `min_df = 5`
- `sublinear_tf = True`

Le dataset a ensuite été séparé en :

- données d'entraînement ;
- données de test.

Les résultats obtenus montrent les dimensions suivantes :

- **Train** : 31 280 articles
- **Test** : 7 820 articles

Matrices TF-IDF :

- **Train** : (31280, 10000)
- **Test** : (7820, 10000)

La densité relativement faible de la matrice confirme le caractère sparse des représentations textuelles obtenues avec TF-IDF.

Table 3: Comparaison des configurations TF-IDF

Paramètre TF-IDF	Configuration FakeNewsNet(≈ 400 articles)	Configuration ISOT(≈ 44 000 articles)	Justification du choix
max_features	5000	10000	Un dataset plus volumineux nécessite un vocabulaire plus riche afin de mieux représenter les données textuelles.
ngram_range	(1, 2)	(1, 2)	Les unigrammes et bigrammes restent pertinents pour capturer le contexte des phrases.
min_df	2	5	Les mots apparaissant dans moins de 5 documents sont considérés comme du bruit sur un grand dataset.
sublinear_tf	True	True	Conservation de la pondération logarithmique TF-IDF afin de réduire l'impact des mots très fréquents.
Jeu de données utilisé pour le fit	X_train	X_train uniquement	Permet d'éviter le problème de <i>data leakage</i> durant l'apprentissage du modèle.

2.5. Modélisation des données textuelles

Après la phase de vectorisation TF-IDF, plusieurs modèles de classification supervisée ont été développés afin de détecter automatiquement les fake news à partir du contenu textuel des articles.

Dans cette étude, deux approches bayésiennes ont été utilisées :

- **Multinomial Naive Bayes ;**
- **Complement Naive Bayes.**

Une **régression logistique** a également été utilisée comme modèle de référence afin de comparer les performances obtenues par les approches bayésiennes.


Les modèles ont été entraînés sur les matrices TF-IDF issues des données textuelles prétraitées.

2.5.1. Modélisation avec Multinomial Naive Bayes

Le modèle **Multinomial Naive Bayes** est particulièrement adapté aux tâches de classification de textes basées sur les fréquences de mots et les représentations TF-IDF. Ce modèle repose sur le théorème de Bayes et suppose une indépendance conditionnelle entre les différentes features textuelles.

Dans ce projet, le modèle a été entraîné sur les données vectorisées afin de prédire automatiquement si un article appartient à la catégorie des fake news ou des real news.

Après l'apprentissage du modèle, des prédictions ont été réalisées sur les données de test afin d'évaluer les performances de classification.



```
MultinomialNB
Accuracy : 0.9645
F1-macro : 0.9642 <- metrique principale
AUC-ROC : 0.9935
AUC-PR : 0.9940
```

	precision	recall	f1-score	support
Fake (0)	0.96	0.96	0.96	3581
Real (1)	0.97	0.97	0.97	4239
accuracy			0.96	7820
macro avg	0.96	0.96	0.96	7820
weighted avg	0.96	0.96	0.96	7820

Figure 18: Recherche alpha MultinomialNB

Interpretation :

Sur ISOT, le F1-macro devrait dépasser 0.90 — une amélioration

radicale par rapport aux 0.39 d'accuracy obtenus sur FakeNewsNet corrompus.

Cette hausse confirme que le problème précédent était exclusivement data, pas algorithmique.

L'accuracy est maintenant une métrique lisible grâce à l'équilibre quasi-parfait du dataset.




Figure 19:Matrice de confusion MultinomialNB

Interpretation : La matrice de confusion permet de quantifier les erreurs residuelles.

Les faux positifs (Fake classifie Real) restent les erreurs les plus critiques

dans un contexte de detection de desinformation — une fake news non detectee

continue a circuler. Sur ISOT, le nombre de ces erreurs devrait etre tres faible

grace a la nettete de la separation lexicale entre les deux sources.

2.5.2. Modélisation avec Complement Naive Bayes

Le modèle **Complement Naive Bayes** constitue une amélioration du modèle Naive Bayes classique pour les données textuelles fortement sparse. Il est souvent plus robuste sur les grands datasets de classification de textes.

Le modèle a été entraîné sur les mêmes représentations TF-IDF afin de comparer ses performances avec celles du modèle Multinomial Naive Bayes.

Les résultats obtenus permettent d'évaluer la capacité du modèle à distinguer efficacement les fake news des informations réelles.

```
ComplementNB (alpha=0.01)
Accuracy : 0.9634
F1-macro : 0.9632 <- metrique principale
AUC-ROC : 0.9935
AUC-PR : 0.9940
```

	precision	recall	f1-score	support
Fake (0)	0.96	0.96	0.96	3581
Real (1)	0.97	0.96	0.97	4239
accuracy			0.96	7820
macro avg	0.96	0.96	0.96	7820
weighted avg	0.96	0.96	0.96	7820

Figure 20:Performance ComplementNB

Interpretation :

Sur un dataset quasi-equilibre comme ISOT, MultinomialNB et ComplementNB devraient afficher des performances proches. Si CNB reste superieur, cela suggere que la modelisation inverse apporte un benefice independamment du desequilibre — possiblement lie a la distribution asymetrique des sujets (politique americaine vs international).

2.5.3. Régression Logistique

La régression logistique a été utilisée comme modèle de référence afin de comparer les performances des approches bayésiennes avec une méthode de classification supervisée linéaire.

Ce modèle est particulièrement performant dans les tâches de classification de textes utilisant des représentations vectorielles TF-IDF. Les résultats obtenus permettent de comparer les performances globales des modèles développés dans cette étude.

```

Logistic Regression (sans class_weight)
Accuracy : 0.9907
F1-macro : 0.9906 <- metrique principale
AUC-ROC : 0.9994
AUC-PR : 0.9995

              precision    recall  f1-score   support

Fake (0)       1.00        0.98        0.99        3581
Real (1)        0.99        1.00        0.99        4239

   accuracy                   0.99        7820
  macro avg       0.99        0.99        0.99        7820
 weighted avg     0.99        0.99        0.99        7820

```

Figure 21: Performance Logistic Regression

Interpretation : La regression logistique sert de plafond de reference pour les approches TF-IDF. Si elle surpasse significativement Naive Bayes, cela indique que les relations entre features sont importantes et que l'hypothese d'indépendance de NB est trop restrictive.

Sur ISOT, la LR atteint typiquement une accuracy > 0.98 — ce niveau de performance reflète la netteté de la separation lexicale entre Reuters et les sources de fake news.

2.6. Évaluation comparative des modèles

Afin d'évaluer les performances des modèles développés, plusieurs métriques de classification ont été utilisées :

- Accuracy ;
- Precision ;
- Recall ;

- F1-score.

Une comparaison globale des performances a ensuite été réalisée afin d'identifier le modèle le plus performant pour la détection automatique des fake news.

Les résultats montrent que les approches bayésiennes offrent d'excellentes performances sur le dataset ISOT Fake News grâce à leur bonne adaptation aux données textuelles vectorisées.

	Modele	F1-macro	Accuracy	AUC-ROC	AUC-PR
	MultinomialNB (FakeNewsNet – labels corrompus)	–	0.39	0.26	–
	MultinomialNB (ISOT)	0.9642	0.9645	0.9935	0.9940
	ComplementNB (ISOT)	0.9632	0.9634	0.9935	0.9940
	Logistic Regression (ISOT)	0.9906	0.9907	0.9994	0.9995
	LinearSVC (ISOT)	0.9965	0.9965	0.9999	0.9999
	SGDClassifier (ISOT)	0.9880	0.9881	0.9990	0.9991
	Passive-Aggressive (ISOT)	0.9957	0.9958	0.9999	0.9999

Figure 22:Tableau comparatif modèles




Figure 23:Heatmap des performances




Figure 24: Courbes ROC et PR

Interpretation :

Sur ISOT, les courbes ROC et PR devraient être très proches du coin supérieur gauche pour tous les modèles — signe d'une classification presque parfaite. La séparation visuelle entre les modèles sera faible, ce qui est normal : quand le signal dans les données est très fort (vocabulaire Reuters vs fake news politiques), même un modèle simple comme Naive Bayes capture l'essentiel de l'information.




Figure 25: Confusions Multinomial vs ComplementNB

2.6.1. Validation croisée

Une validation croisée (*Cross Validation*) à 5 folds a été réalisée afin d'évaluer la stabilité et la robustesse des modèles sur différentes partitions des données.

Cette étape permet de vérifier la capacité de généralisation des modèles et de réduire le risque de surapprentissage.

Modele	F1-macro	F1 std	Accuracy	Acc std
-----	-----	-----	-----	-----
MultinomialNB	0.9627	0.0022	0.9629	0.0022
MultinomialNB	0.9627	0.0022	0.9629	0.0022
ComplementNB	0.9626	0.0025	0.9629	0.0024
ComplementNB	0.9626	0.0025	0.9629	0.0024
LogisticRegression	0.9905	0.0012	0.9906	0.0012
LogisticRegression	0.9905	0.0012	0.9906	0.0012
LinearSVC	0.9966	0.0005	0.9966	0.0005
LinearSVC	0.9966	0.0005	0.9966	0.0005
SGDClassifier	0.9865	0.0010	0.9866	0.0010
SGDClassifier	0.9865	0.0010	0.9866	0.0010
PassiveAggressive	0.9962	0.0006	0.9962	0.0006
PassiveAggressive	0.9962	0.0006	0.9962	0.0006

Figure 26:Table comparatif F1 et Accuracy

Interpretation :

Avec 44 000 articles, l'ecart-type entre folds devrait etre tres faible (< 0.005), confirmant la robustesse statistique des resultats.

C'est un contraste saisissant avec FakeNewsNet (400 articles, $\text{std} \approx 0.08$) :

la taille du dataset est le facteur le plus determinant pour la fiabilite des evaluations.

Ces resultats sont reproductibles et generalisables au sein de la distribution ISOT.

2.6.2. Analyse des features discriminantes




Figure 27: Features discriminants ISOT

Interpretation :

Sur ISOT, les features discriminantes refléteront clairement la signature stylistique de Reuters (formules journalistiques institutionnelles, citations officielles, datelines) versus le style des fake news politiques américaines (noms propres controverses, expressions émotionnelles).

Les bigrammes seront particulièrement révélateurs : des expressions comme 'said reuters', 'according', 'washington reuters' caractérisent fortement les real news, tandis que les fake news auront leurs propres expressions récurrentes.

Faux Positifs (Fake classifié comme Real) : 148

Faux Négatifs (Real classifié comme Fake) : 130

Taux d'erreur global : 3.55%

Exemples de Faux Positifs (Fake News non détectées) :

[proba_real=0.95] puerto rico next detroit entire situation puerto rico reminds bailouts financial industry like big fail mantra heard financial crisis obama ...

[proba_real=0.65] amb nikki haley show photo shock security council continue see picture unsee video breaking amb haley show image child victimized syria chem...

Exemples de Faux Negatifs (Real News mal classees) :

[proba_real=0.47] warren keep assault white house hopeful trump judge comment washington reuters democratic senator elizabeth warren keep assault republican p...

[proba_real=0.04] election loom trump say last chance clinton see moment reckonin g manchester sterling height michigan reuters donald trump hillary clinton cr...

Interpretation : Les erreurs residuelles sur ISOT sont rares et revelent

les cas limites du dataset : des fake news redigees dans un style Reuters inhabituel, ou des real news couvrant des sujets politiques americains avec un vocabulaire proche de celui des fake news. Ces cas frontiere illustrent la limite d'une approche purement lexicale — un modele contextuel (BERT) les gererait mieux.

Limites et perspectives

Les performances elevees sur ISOT doivent etre interpretees avec nuance :

la separation lexicale entre Reuters et les sources de fake news est particulierement nette, ce qui rend la tache plus facile que dans des scenarios reels ou les fake news imitent le style des vraies sources.

Pour un systeme de detection plus robuste et generalisable :

1. Tester sur un dataset out-of-distribution (LIAR, WELFake) pour evaluer la generalisation hors de la distribution ISOT
2. Integrer des features numeriques (caps_ratio, excl_ratio) aux cotes de TF-IDF via ``scipy.sparse.hstack``
3. Remplacer TF-IDF + Naive Bayes par un modele transformer (BERT, RoBERTa) pour capturer le contexte semantique au-dela du vocabulaire

Conclusion du Chapitre 2

Dans ce chapitre, nous avons présenté les différentes étapes de développement du système de détection automatique des fake news, depuis la préparation des données jusqu'à l'évaluation des modèles de classification.

Les résultats obtenus montrent l'efficacité des approches bayésiennes appliquées aux représentations TF-IDF pour la classification des articles de presse. La comparaison avec la régression logistique a également permis d'analyser les performances des différents modèles développés.

Le chapitre suivant sera consacré à la conception et au développement de l'application web interactive permettant la détection des fake news en temps réel.

Chapitre 3 : Conception et développement de l'application web de détection des fake news

Introduction du Chapitre 3

Après avoir présenté les différentes étapes de préparation des données, de vectorisation TF-IDF et de développement des modèles de classification dans le chapitre précédent, ce troisième chapitre est consacré à la conception et au développement de l'application web FakeShield dédiée à la détection automatique des fake news.

L'objectif principal de cette application est de rendre les modèles de Machine Learning développés précédemment accessibles à travers une interface web moderne, interactive et facile à utiliser. Pour cela, une architecture client-serveur a été mise en place en séparant le frontend, développé avec React et Vite, du backend conçu avec FastAPI. Cette organisation permet d'assurer une communication fluide entre l'interface utilisateur et les modèles de classification intégrés dans le serveur backend.

Ce chapitre présente également les choix technologiques adoptés, l'architecture générale de l'application, le fonctionnement des différentes interfaces utilisateur ainsi que l'intégration des modèles de Machine Learning dans une API REST. Les principales fonctionnalités développées, telles que l'analyse des textes, le dashboard statistique, l'historique des analyses et le chatbot intelligent basé sur Gemini AI, seront également détaillées.

3.1. Architecture générale de l'application

L'architecture de notre application web FakeShield est organisée en trois couches principales : frontend, backend et API d'inférence du modèle de Machine Learning.

3.2. Backend API FastAPI

Le backend de l'application FakeShield a été développé avec le framework **FastAPI**, choisi pour ses hautes performances, sa rapidité d'exécution et sa bonne compatibilité

avec les applications de Machine Learning en Python. Il permet de construire une API REST moderne capable de traiter efficacement les requêtes provenant du frontend.



Figure 28:FastAPI + Python

L'architecture du backend est organisée de manière modulaire afin de faciliter la maintenance et la lisibilité du code. Le fichier principal `main.py` constitue le point d'entrée de l'application et contient la configuration générale du serveur ainsi que les paramètres de communication.

Le backend intègre également un chatbot intelligent utilisant l'**API Gemini** afin de fournir des réponses contextuelles et des explications sur les résultats de classification.



Figure 29:Gemini API

3.3. Frontend Interface React

Le frontend de FakeShield a été développé avec React et Vite afin de créer une interface moderne, rapide et responsive. L'application est organisée sous forme de composants réutilisables et de pages interactives facilitant la navigation et la maintenance du projet.

La page principale permet à l'utilisateur de saisir un texte à analyser puis d'afficher dynamiquement le résultat de classification sous forme visuelle avec le niveau de confiance du modèle. L'interface intègre également un chatbot contextuel ainsi qu'un dashboard statistique contenant plusieurs graphiques interactifs réalisés avec Recharts. Une page Historique permet de consulter les dernières analyses effectuées, tandis qu'une page À propos présente les objectifs du projet et les modèles utilisés.



Figure 30:Vite + React

3.4. Intégration des modèles ML dans l'application

Les modèles de Machine Learning entraînés ont été sauvegardés au format `.pkl` afin d'être intégrés directement dans l'application web. Lors du démarrage du serveur FastAPI, les modèles ainsi que le vectoriseur TF-IDF sont chargés en mémoire afin d'optimiser les performances.

Le pipeline de traitement suit plusieurs étapes : réception du texte, prétraitement, vectorisation TF-IDF, exécution des modèles Naïve Bayes puis génération de la réponse finale au format JSON. Cette architecture permet d'obtenir des prédictions rapides et fluides en temps réel.




Figure 31: pipeline d'integration models ML

4. Interface utilisateur

4.1. Page principale : Analyse de texte et résultats dynamiques

L'interface principale de FakeShield, illustrée dans la figure ci-dessous, présente une page d'analyse. L'utilisateur peut y coller n'importe quel article ou texte afin d'obtenir un verdict instantané, tandis que la barre de navigation supérieure donne accès aux différentes fonctionnalités de l'application : analyse, tableau de bord, historique et documentation.



Figure 32:page d'accueil de FakeShield pour analyser un texte et détecter la désinformation.

4.1.1 Résultat de détection Fake News

Après soumission d'un texte, l'application affiche un verdict FAKE en rouge avec un score de confiance de 61.4% contre 38.6% pour REAL. Dans le panneau des indicateurs détectés, quatre mots discriminants ont orienté la décision vers le fake : *news*, *sheeple*, *wake* et *fake*. Le texte analysé comptait 21 mots avec un ratio de majuscules de 1%.




Figure 33:interface affichant un verdict “FAKE” avec indicateurs détectés.

4.1.2 Résultat de détection Real News

La figure montre l'analyse d'un article portant sur les projets d'énergie renouvelable du gouvernement marocain. Le verdict retourné est REAL en vert, avec un score de confiance de 62.7% contre 37.3% pour FAKE. Le texte analysé est nettement plus long avec 110 mots et un ratio de majuscules de 1%. Les mêmes indicateurs sont affichés à titre informatif.




Figure 34: interface affichant un verdict “REAL” avec score de confiance.

4.1.3 Chatbot ntelligent




Figure 35:Assistant FakeShield

Le chatbot intégré à l'application, alimenté par l'API Gemini, offre une interaction contextuelle autour du résultat d'analyse. L'utilisateur pose deux questions successives : la première sur les raisons du verdict FAKE, la seconde sur le niveau de confiance du modèle. L'assistant répond de manière pédagogique en expliquant les indicateurs détectés et en fournissant une grille d'interprétation du score de confiance (> 80% très fiable, 60–80% fiable, < 60% incertain).

4.2. Dashboard statistique

Le tableau de bord de FakeShield offre une visualisation en temps réel des statistiques de détection. Il regroupe des cartes de comptage (total d'analyses, fakes et réels détectés), un camembert de répartition des verdicts, un histogramme de distribution des scores de confiance, une timeline d'évolution des prédictions, ainsi qu'un graphique comparant les performances des deux modèles — ComplementNB et MultinomialNB — sur les métriques Accuracy, Precision, Recall et F1-Score.




Figure 36:Dashboard FakeShield Réel




Figure 37:Dashboard FakeShield Fake

4.3 Page Historique

Cette Figure présente l'interface « Historique » de l'application FakeShield. Elle permet aux utilisateurs de consulter les analyses précédemment effectuées sur différents articles. L'interface affiche les informations principales comme la date, le

titre de l'article, la source, le résultat de détection ainsi que le score de confiance du modèle.

Le design sombre et moderne améliore la lisibilité et l'expérience utilisateur.

Date	Titre de l'article	Source	Résultat	Score	
12/08/2025	"Le Maroc lance une nouvelle monnaie digitale nationale"	Social Media Post	Fake	92%	Voir détails >
10/08/2025	"L'OMS confirme une nouvelle pandémie mondiale"	Blog News 24	Fake	88%	Voir détails >
08/08/2025	"Apple annonce un iPhone entièrement transparent en 2026"	Tech Vision	Fake	95%	Voir détails >
05/08/2025	"La Coupe du Monde 2030 sera organisée au Maroc, Espagne et Portugal"	FIFA Official	Réel	98%	Voir détails >
03/08/2025	"Découverte d'une cité perdue sous le désert du Sahara"	Viral News	Fake	85%	Voir détails >

Figure 38: Historique FakeShield

4.4 Page À propos

Cette interface présente les principales informations techniques de l'application FakeShield.

Elle décrit le dataset utilisé, le modèle d'intelligence artificielle basé sur Naive Bayes et TF-IDF, ainsi que les performances obtenues par le système.

La page présente également l'architecture générale de l'application développée avec ReactJS, FastAPI et Python.

Un schéma du pipeline de traitement illustre les différentes étapes de détection des fake news, depuis la saisie du texte jusqu'à l'affichage du résultat final.




Figure 39:À propos FakeShield

3.5. Tests de l'application

Afin d'assurer la fiabilité de FakeShield, plusieurs tests ont été réalisés sur le classificateur et les endpoints de l'API backend.

3.5.1. Tests unitaires du classificateur

Les tests du fichier tests/test_classifier.py permettent de vérifier :

- le chargement correct des modèles .pkl et du vectoriseur TF-IDF ;
- la validité des prédictions sur des exemples de fake news et de vraies informations ;
- le calcul des probabilités et du score de confiance ;
- le bon fonctionnement du mécanisme de fallback basé sur des mots-clés en cas d'absence des modèles.

Ces tests garantissent la stabilité et la fiabilité du module de classification.

3.5.2. Tests de l'API

Les tests de l'API ont été réalisés avec pytest et httpx dans le fichier tests/test_api.py.

Ils permettent de vérifier :

- la disponibilité du serveur ;
- le fonctionnement des endpoints /analyze, /history, /stats et /chat ;
- la validité des réponses JSON retournées au frontend.

Ces tests assurent une communication correcte entre React et FastAPI.

3.5.3. Génération des modèles de démonstration

Le script create_demo_models.py permet de générer rapidement des modèles de démonstration pour les phases de développement et de test.

Il assure :

- la création d'un dataset simplifié ;
- l'entraînement de modèles Naive Bayes ;
- la génération du vectoriseur TF-IDF ;

Conclusion du Chapitre 3

Dans ce chapitre, nous avons présenté la conception et le développement de l'application web FakeShield dédiée à la détection automatique des fake news. L'application repose sur une architecture client-serveur moderne séparant le frontend développé avec React et Vite du backend conçu avec FastAPI et Python.

Nous avons également détaillé l'intégration des modèles de Machine Learning basés sur TF-IDF et Naive Bayes dans une API REST capable de fournir des prédictions rapides et fiables en temps réel. Plusieurs fonctionnalités ont été développées afin d'améliorer l'expérience utilisateur, notamment l'analyse automatique des textes, le

dashboard statistique interactif, l'historique des analyses ainsi que le chatbot intelligent basé sur Gemini AI.

Enfin, les différents tests réalisés sur le classificateur et les endpoints de l'API ont permis de garantir la stabilité, la fiabilité et le bon fonctionnement global du système.

Ce chapitre constitue ainsi une étape importante du projet puisqu'il permet de transformer les modèles de classification développés précédemment en une application web complète, interactive et exploitable par les utilisateurs.

Conclusion Générale

Ce projet a démontré l'efficacité des approches de **classification bayésienne** (MultinomialNB et ComplementNB) dans la détection automatique des fake news politiques, en exploitant le dataset **ISOT** et la vectorisation **TF-IDF**. Les résultats obtenus (accuracy et F1-score supérieurs à 94 %) confirment la pertinence de ces modèles pour des tâches de classification textuelle.

La comparaison avec des modèles linéaires de référence (Logistic Regression, LinearSVC, SGDClassifier, Passive-Aggressive) a permis de mettre en évidence que certains algorithmes surpassent légèrement les Naive Bayes en termes de performance, mais au prix d'une complexité computationnelle plus élevée.

Au-delà de l'analyse expérimentale, la réalisation d'une application web interactive avec **FastAPI** et un dashboard dynamique illustre la faisabilité d'un outil pratique de détection de désinformation utilisable en temps réel. Ce travail souligne ainsi l'importance des techniques d'**intelligence artificielle** et de **NLP** dans la lutte contre la désinformation numérique, tout en ouvrant des perspectives pour des améliorations futures (intégration de modèles profonds, enrichissement du dataset, multilinguisme).

Annexes

1. Préprocessement NLP

```
stop_words = set(stopwords.words('english'))
lemmatizer = WordNetLemmatizer()

def clean_text(text):
    text = str(text).lower()
    text = re.sub(r'http\S+|www.\S+', ' ', text)
    text = re.sub(r'<.*?>', ' ', text)
    text = re.sub(r'^a-z\s', ' ', text)
    tokens = word_tokenize(text)
    tokens = [
        lemmatizer.lemmatize(t)
        for t in tokens
        if t not in stop_words and len(t) > 2
    ]
    return ' '.join(tokens)

print('Preprocessement en cours (peut prendre quelques minutes sur 44 000 articles)...')
df_all['clean'] = df_all['statement'].apply(clean_text)
df_all = df_all[df_all['clean'].str.strip().str.len() > 10].reset_index(drop=True)

print(f'Shape apres NLP : {df_all.shape}')
print()
df_all[['statement', 'clean', 'label']].head(3)
```

2. Les histogrammes de longueur des textes par classe et Les boxplots du nombre de mots

```
# Distribution de la longueur et du nombre de mots
# Palette avec des string pour compatibilité seaborn >= 0.12
df_all['text_length'] = df_all['clean'].str.len()
df_all['word_count'] = df_all['clean'].str.split().str.len()
df_all['label_str'] = df_all['label'].map({0: 'Fake (0)', 1: 'Real (1)'})

palette = {'Fake (0)': '#C0392B', 'Real (1)': '#2980B9'}

fig, axes = plt.subplots(1, 2, figsize=(12, 4))

sns.histplot(data=df_all, x='text_length', hue='label_str', bins=60, kde=True,
             palette=palette, ax=axes[0])
axes[0].set_title('Distribution de la longueur des textes')
axes[0].set_xlabel('Nombre de caracteres')
axes[0].legend(title='Classe')

sns.boxplot(data=df_all, x='label_str', y='word_count',
            palette=palette, ax=axes[1],
            order=['Fake (0)', 'Real (1)'])
axes[1].set_xlabel('Classe')
axes[1].set_title('Nombre de mots par classe')
axes[1].set_ylabel('Nombre de mots')

plt.tight_layout()
plt.show()

print('Statistiques descriptives :')
print(df_all.groupby('label_str')[['text_length', 'word_count']].describe().round(1).to_string())
```

3. Les WordClouds Fake vs Real

```
# Wordclouds
# Echantillon pour accelerer la generation (50 000 mots max par classe)
fake_text = ' '.join(df_all[df_all['label'] == 0]['clean'].sample(
    min(5000, (df_all['label']==0).sum()), random_state=42))
real_text = ' '.join(df_all[df_all['label'] == 1]['clean'].sample(
    min(5000, (df_all['label']==1).sum()), random_state=42))

wc_fake = WordCloud(width=800, height=350, background_color='white',
                    colormap='Reds', max_words=100).generate(fake_text)
wc_real = WordCloud(width=800, height=350, background_color='white',
                    colormap='Blues', max_words=100).generate(real_text)

fig, axes = plt.subplots(1, 2, figsize=(14, 4))
axes[0].imshow(wc_fake); axes[0].axis('off')
axes[0].set_title('Fake News - mots dominants')
axes[1].imshow(wc_real); axes[1].axis('off')
axes[1].set_title('Real News - mots dominants')
plt.tight_layout()
plt.show()
```

4. distribution subject par classe

```
# Distribution des sujets par classe
subject_dist = df_all.groupby(['label_str', 'subject']).size().reset_index(name='count')

fig, axes = plt.subplots(1, 2, figsize=(14, 5))

for ax, label, color in [
    (axes[0], 'Fake (0)', '#C0392B'),
    (axes[1], 'Real (1)', '#2980B9')
]:
    data = subject_dist[subject_dist['label_str'] == label].sort_values('count', ascending=True)
    ax.barh(data['subject'], data['count'], color=color)
    ax.set_title(f'Distribution des sujets - {label}')
    ax.set_xlabel('Nombre d articles')

plt.tight_layout()
plt.show()
```

5. La heatmap de corrélation des features textuelles.

```

corr_matrix = df_feat.corr()

fig, ax = plt.subplots(figsize=(9, 7))
sns.heatmap(
    corr_matrix,
    annot=True, fmt='.2f',
    cmap='RdBu_r', center=0,
    vmin=-1, vmax=1,
    linewidths=0.5,
    ax=ax
)
ax.set_title('Heatmap de correlation - features textuelles numeriques', pad=14)
plt.tight_layout()
plt.show()

print('Correlations avec le label (tri decroissant) :')
print(corr_matrix['label'].drop('label').sort_values(ascending=False).round(4).to_string())

```

6. Paramétrage TF-IDF et GridSearch

```

tfidf = TfidfVectorizer(
    max_features=10000,
    ngram_range=(1, 2),
    min_df=5,
    sublinear_tf=True,
    strip_accents='unicode'
)

X_train = tfidf.fit_transform(X_train_text)
X_test = tfidf.transform(X_test_text)

print(f'Matrice train : {X_train.shape}')
print(f'Matrice test : {X_test.shape}')
print(f'Densite de la matrice : {X_train.nnz / (X_train.shape[0] * X_train.shape[1]):.5f}')

```

7. Modèles supplémentaires

```

# Linear SVM
svc = LinearSVC()
svc.fit(X_train, y_train)
y_pred_svc = svc.predict(X_test)
y_score_svc = svc.decision_function(X_test)
acc_svc, f1_mac_svc, auc_svc, ap_svc = compute_metrics(y_test, y_pred_svc, y_score_svc)

print('LinearSVC')
print(f' Accuracy : {acc_svc:.4f}')
print(f' F1-macro : {f1_mac_svc:.4f} <- metrique principale')
print(f' AUC-ROC : {auc_svc:.4f}')
print(f' AUC-PR : {ap_svc:.4f}')
print()

# SGDClassifier (logistic regression stochastique)
sgd = SGDClassifier(loss='log_loss', max_iter=1000, tol=1e-3, random_state=42)
sgd.fit(X_train, y_train)
y_pred_sgd = sgd.predict(X_test)
y_proba_sgd = sgd.predict_proba(X_test)[: , 1]
acc_sgd, f1_mac_sgd, auc_sgd, ap_sgd = compute_metrics(y_test, y_pred_sgd, y_proba_sgd)

print('SGDClassifier (log_loss)')
print(f' Accuracy : {acc_sgd:.4f}')
print(f' F1-macro : {f1_mac_sgd:.4f} <- metrique principale')
print(f' AUC-ROC : {auc_sgd:.4f}')
print(f' AUC-PR : {ap_sgd:.4f}')
print()

# Passive-Aggressive
pa = PassiveAggressiveClassifier(max_iter=1000, random_state=42)
pa.fit(X_train, y_train)

```

8. Visualisations de performance

```
# Courbes ROC + Precision-recall
fig, axes = plt.subplots(1, 2, figsize=(14, 5))

model_specs = [
    ('MultinomialNB', y_proba_mnb, auc_mnb, ap_mnb, '#2980B9'),
    ('ComplementNB', y_proba_cnb, auc_cnb, ap_cnb, '#27AE60'),
    ('Logistic Reg.', y_proba_lr, auc_lr, ap_lr, '#8E44AD'),
    ('LinearSVC', y_score_svc, auc_svc, ap_svc, '#F39C12'),
    ('SGD (log_loss)', y_proba_sgd, auc_sgd, ap_sgd, '#16A085'),
    ('Passive-Agg.', y_score_pa, auc_pa, ap_pa, '#7F8C8D'),
]

for name, scores, auc, ap, color in model_specs:
    fpr, tpr, _ = roc_curve(y_test, scores)
    axes[0].plot(fpr, tpr, color=color, label=f'{name} (AUC={auc:.3f})')
    prec, rec, _ = precision_recall_curve(y_test, scores)
    axes[1].plot(rec, prec, color=color, label=f'{name} (AP={ap:.3f})')

axes[0].plot([0, 1], [0, 1], '--', color='gray', label='Baseline aleatoire')
axes[0].set_xlabel('Taux de faux positifs (FPR)')
axes[0].set_ylabel('Taux de vrais positifs (TPR)')
axes[0].set_title('Courbes ROC')
axes[0].legend(fontsize=9)

baseline_pr = (y_test == 1).mean()
axes[1].axhline(baseline_pr, color='gray', linestyle='--',
                label=f'Baseline aleatoire ({baseline_pr:.2f})')
axes[1].set_xlabel('Recall')
axes[1].set_ylabel('Precision')
axes[1].set_title('Courbes Precision-Recall')
axes[1].legend(fontsize=9)
```

9. Validation croisée

```
tfidf_params = dict(
    max_features=10000, ngram_range=(1, 2),
    min_df=5, sublinear_tf=True
)

pipes = {
    'MultinomialNB': Pipeline([('tfidf', TfidfVectorizer(**tfidf_params)),
                              ('clf', MultinomialNB(alpha=best_alpha_mnb))]),
    'ComplementNB': Pipeline([('tfidf', TfidfVectorizer(**tfidf_params)),
                              ('clf', ComplementNB(alpha=best_alpha_cnb))]),
    'LogisticRegression': Pipeline([('tfidf', TfidfVectorizer(**tfidf_params)),
                                    ('clf', LogisticRegression(max_iter=1000, C=1.0))]),
    'LinearSVC': Pipeline([('tfidf', TfidfVectorizer(**tfidf_params)),
                           ('clf', LinearSVC())]),
    'SGDClassifier': Pipeline([('tfidf', TfidfVectorizer(**tfidf_params)),
                               ('clf', SGDClassifier(loss='log_loss', max_iter=1000,
                                                       tol=1e-3, random_state=42))]),
    'PassiveAggressive': Pipeline([('tfidf', TfidfVectorizer(**tfidf_params)),
                                   ('clf', PassiveAggressiveClassifier(max_iter=1000,
                                                                        random_state=42))]),
}

print(f'{"Modele":<22} {"F1-macro":>10} {"F1 std":>8} {"Accuracy":>10} {"Acc std":>8}')
print('-' * 65)
for name, pipe in pipes.items():
    f1 = cross_val_score(pipe, X_text, y, cv=5, scoring='f1_macro', n_jobs=-1)
    acc = cross_val_score(pipe, X_text, y, cv=5, scoring='accuracy', n_jobs=-1)
    print(f'{name:<22} {f1.mean():>10.4f} {f1.std():>8.4f} '
          f'{acc.mean():>10.4f} {acc.std():>8.4f}')
```

Webgraphie

[Pew Research Center – Misinformation](#) : Études sur l'impact des fake news et la perception du public

[ISOT Fake News Dataset – University of Victoria](#) : Description officielle du dataset ISOT Fake News

[Scikit-learn – TfidfVectorizer Documentation](#) : Documentation officielle sur la vectorisation TF-IDF

[FastAPI – Documentation officielle](#) : Framework Python pour le développement d'API

[Springer – Exploring Machine Learning for Fake News Detection](#) : Article académique sur l'utilisation du Machine Learning pour la détection des fake news